

Identificação de Transações Fraudulentas em Cartões de Crédito

Clustering com K-Means e DBSCAN sobre dados reduzidos por PCA

EQUIPE

Caio Rebert Oliveira da Silva

Gabriel Soares de Vasconcelos Lira

Jadson Vinicius Ramos de Souza

Silas Eduardo Rodrigues dos Santos

O Desafio

Encontrar padrões de fraude sem rótulos

Transações de cartão de crédito foram limpas, enriquecidas (hora, dia da semana, idade) e reduzidas a 9 variáveis numéricas, padronizadas com StandardScaler antes da aplicação de técnicas de clustering não supervisionado.

1,3M

registros tratados

9

variáveis numéricas usadas

0,58%

taxa de fraude (classe rara)

26 → 9

redução de colunas


Variáveis utilizadas na modelagem:

amt · lat · long · city_pop · merch_lat · merch_long · trans_hour · trans_day_of_week · age



Fraude é um evento raro e desbalanceado — o que torna a tarefa de agrupamento naturalmente mais difícil.

PCA: comprimindo 9 variáveis preservando informação



- 1

6 componentes
preservam ~90% da variância dos dados
- 2

7 componentes
preservam ~95% da variância dos dados
- 3

Sem separação clara
fraudes aparecem misturadas às transações normais nas projeções 2D/3D

Conclusão: o PCA comprime os dados com eficiência, mas a fraude não é linearmente separável apenas pelos primeiros componentes.

K-Means vs. DBSCAN sobre o espaço PCA (90%)



K-Means

Melhor $K = 4$, definido pelo método do cotovelo (maior distância ortogonal à reta da curva de inércia).

Distribuição das amostras por cluster:

394.726 · 641.925 · 219.195 · 40.829

Particiona TODOS os pontos em 4 grupos esféricos — sem noção de ruído ou anomalia.



DBSCAN

Busca por densidade entre ϵ e min_samples , testada em 3 amostras de 1% dos dados.

Melhor configuração encontrada:

$\epsilon = 0,10$ · $\text{min_samples} = 3$

Apenas 2 clusters formados — e 12.960 dos 12.966 pontos (99,95%) foram classificados como ruído.

Métricas internas: números altos, utilidade baixa

Modelo	Clusters	Ruídos (-1)	Silhouette	Davies-Bouldin	Dunn
K-Means	4	0	0,2343	1,3520	0,0054
DBSCAN	2	12.960	0,9876	0,0139	45,6004



DBSCAN: métrica enganosa

Silhouette de 0,98 reflete apenas a alta separação entre os pouquíssimos pontos densos restantes — não a qualidade do agrupamento sobre o dataset real, quase todo descartado como ruído.



K-Means: estrutura forçada

Silhouette baixo (0,23) indica que o algoritmo foi forçado a dividir os dados em 4 grupos sem uma estrutura natural de separação clara no espaço do PCA.

Conclusão

Clustering espacial não detecta fraude sozinho

Nenhum dos dois modelos isolou a variável `is_fraud` com eficiência. O K-Means atuou como um classificador geodemográfico — o Grupo 3 concentrou exclusivamente cidades de grande população (`city_pop`), sem relação com fraude.



PCA reduz dimensionalidade bem, mas perde a separação da fraude



K-Means encontra perfis regionais de usuários, não fraudadores



DBSCAN só funciona como detector de ruído extremo, não de fraude



Próximo passo: Engenharia de Features comportamentais e temporais



Diagnóstico final

12.960 / 12.966

pontos rotulados como ruído pelo DBSCAN —
99,95% da amostra testada

0,58%

taxa real de fraude na base — o verdadeiro desafio
de classes desbalanceadas